

# Machine learning para predições em saúde

Prof. Dr. Alexandre Chiavegatto Filho



## 19. Machine Learning para Predições em Saúde – MLS (PRESENCIAL)

**Descrição:** Introduzir as aplicações práticas de machine learning para realizar predições na área da saúde. O objetivo do curso é introduzir as aplicações práticas de machine learning para realizar predições na área da saúde. Programa: 1 – Perspectivas do uso de inteligência artificial em saúde. 2 – Pré-processamento dos dados (padronização, one-hot encoding, imputação, outliers, rebalanceamento, vazamento de informação). 3 – Sobreajuste e divisão da amostra em treino, validação e teste. 4 – Mensuração da performance de algoritmos preditivos (área abaixo da curva ROC, precisão, recall, especificidade, valor predito negativo e raiz quadrada do erro quadrático médio). 5 – Algoritmos para a predição de dados estruturados (regressões penalizadas com lasso e ridge, redes neurais, random forests, XGBoost, lightGBM, catboost e TabPFN). 6 – Técnicas de otimização de hiperparâmetros. 7 – Estratégias para a seleção de variáveis preditoras (Boruta). 8 – Aprendizado federado, aprendizado de transferência e aprendizado online (contínuo). 9 – Estratégias para a identificação da importância de variáveis preditoras (Shapley values). 10 – Desafios éticos do uso de machine learning em saúde.

**Requisito:** Graduandos e Graduados.

**Público:** É importante um conhecimento pelo menos introdutório de estatística e programação. É necessário que o aluno traga notebook.

**Carga horária:** 20h



**Repositório de Arquivos**  
**Machine Learning para Predições em Saúde**



**TIME**  
SPECIAL EDITION

# Artificial Intelligence

The Future of Humankind



INSIDE: A 14-PAGE SPECIAL REPORT ON FINANCIAL TECHNOLOGY

**The Economist**

MAY 9TH - 15TH 2015

economist.com

How to fix America's inner cities  
The self-service economy  
Time to open up Indonesia  
Inside the anti-bribery business  
Why humans cause heatwaves

# Artificial Intelligence

The promise and the peril



THE DECLINE OF INTERNATIONAL

# FOREIGN AFFAIRS

## Hi, Robot

Work and Life in the Age of Automation

The Perils of Special Counsels / This Is Your ISIS on Drugs

**Newsweek**

08.02.2017



**THE DOCTOR WILL SEE YOU NOW**


HOW AI IS GOING TO CURE OUR SICK HEALTH CARE SYSTEM

What it takes to end an AIDS epidemic p. 226 | Polar bears suffer through lean summers p. 205 | Sperm produced in ovary of mutant fish p. 338

# Science

\$10  
17 JULY 2015  
sciencemag.org

MAAAS



SPECIAL ISSUE

**ARTIFICIAL INTELLIGENCE**

OS DOIS RITMOS DA LAVA-JATO  
Curitiba: 107 condenados  
Brasília: nenhum

MADONNA FALA A VEJA  
"Sou uma rebelde e serei rebelde até o fim"

**veja**



## DE MÃOS DADAS COM A INTELIGÊNCIA ARTIFICIAL

Longe dos cenários futurísticos da ficção científica, ela já faz parte do presente. Mas em que medida pode servir ao ser humano e, ao mesmo tempo, ameaçá-lo?



*Inteligência artificial*

NÃO É HYPE CRIADO PELA MÍDIA



**É CONSEQUÊNCIA DOS AVANÇOS  
CIENTÍFICOS DOS ÚLTIMOS ANOS**

**Por que têm ocorrido  
avanços exponenciais  
nos últimos 5 anos?**

**Por que têm ocorrido  
avanços exponenciais  
nos últimos 5 anos?**



Aumento da **quantidade de dados**  
(importante para melhorar performance)



Por que têm ocorrido  
avanços exponenciais  
nos últimos 5 anos?



Aumento da **quantidade de dados**  
(importante para melhorar performance)



Avanços em **capacidade computacional**  
(modelos de *machine learning* exigem  
muita memória).

# Por que têm ocorrido avanços exponenciais nos últimos 5 anos?



Aumento da **quantidade de dados**  
(importante para melhorar performance)



Avanços em **capacidade computacional**  
(modelos de *machine learning* exigem muita memória).



**Novos algoritmos** para problemas mais complexos (*transformers*).

A demanda por profissionais capazes de extrair informação relevante dos dados é muito grande no Brasil e no mundo



The most in-demand skills of 2020

### Top 10 Hard Skills

- |   |                         |     |
|---|-------------------------|-----|
| 1 | Blockchain              | new |
| 2 | Cloud computing         | -1  |
| 3 | Analytical reasoning    | -   |
| 4 | Artificial intelligence | -2  |



# INTELIGÊNCIA ARTIFICIAL

Capacidade de máquinas tomarem decisões inteligentes.

Várias definições para inteligência.

Possibilidade: “capacidade de tomar a melhor decisão possível dada a informação disponível. Com a capacidade de se adaptar a novas situações.”

Segundo essa definição, inteligência é um problema de análise de dados.

# MACHINE LEARNING

## Inteligência artificial *clássica*

Regras para a tomada de decisão ensinada por humanos

- Identificar spam via palavras-chave.
- Traduzir uma frase através de dicionário e regras de gramática.
- Identificar caras humanas por meio da forma de nariz, olho, boca etc.

## Inteligência artificial com *machine learning*

Máquinas aprendendo as regras para a tomada de decisão sozinhas!

Tomada de decisão via identificação de padrões complexos nos dados.

*É como uma  
criança aprende!*




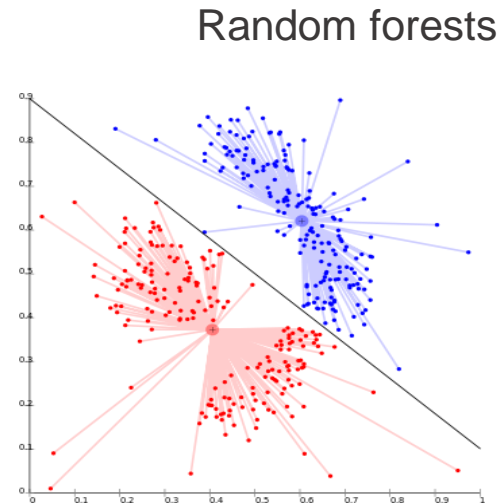



# MACHINE LEARNING

Problemas **práticos** de predição (para a tomada de decisão)

Pouco interesse em *interpretar* os modelos.

Liberdade para modelar a complexidade do mundo real




Regressões penalizadas

### 1. Aprendizado Supervisionado

**Objetivo:** Acertar um resultado que existe.

- Treinar um modelo para obter a melhor performance preditiva possível para um problema;
- Quando os dados incluídos para treinar o algoritmo incluem a solução desejada, ou rótulo (“label”);



# 1. Aprendizado Supervisionado

*Divididos em dois grandes grupos*

## 1. Classificação

Quando a variável a ser predita é categórica.

**Exemplo:** Óbito em 5 anos, incidência de doença em 10 anos, etc.


## 2. Regressão

Quando a variável a ser predita é quantitativa

**Exemplo:** Quantos meses de vida a pessoa tem pela frente, qual será o seu IMC no próximo ano, etc.


## 2. Aprendizado não-supervisionado

- Não existe rótulo (“label”);
- Algoritmo aprende sem uma resposta certa;
- O objetivo é encontrar padrões nos dados;
- Mais comuns: clustering (agrupamentos) e redução de dimensão (ACP).



### 3. Aprendizado por reforço

- Agente interage com um ambiente dinâmico;
- Feedbacks constantes em termos de premiações e punições;
- Jogos.






### 3. Aprendizado por reforço

## QUATRO CATEGORIAS DE MACHINE LEARNING

Área promissora:

- Diferentes etapas do tratamento médico para identificar sequência ótima (ex: sepse).




Gottesman O, Johansson F, Komorowski M, Faisal A, Sontag D, Doshi-Velez F, Celi LA. Guidelines for reinforcement learning in healthcare. Nat Med 2019. 25(1)16-18.

## 4. Autossupervisionado

### QUATRO CATEGORIAS DE MACHINE LEARNING

- Um problema não supervisionado é transformado em um problema supervisionado pela geração automática dos rótulos;
- O processo de aprendizado autossupervisionado consiste em identificar partes ocultas dos dados.

- ▶ Predict any part of the input from any other part.
- ▶ Predict the **future** from the **past**.
- ▶ Predict the **future** from the **recent past**.
- ▶ Predict the **past** from the **present**.
- ▶ Predict the **top** from the **bottom**.
- ▶ Predict the occluded from the visible
- ▶ **Pretend there is a part of the input you don't know and predict that.**




## Pre-training

😊 **Next token prediction**

😞 **Not expert at following instructions**

*write a bedtime \_*

*story*



## Supervised fine-tuning

**fine-tune**



(instruction, response)



**Follow instructions**

## Reinforcement Learning

**Reinforcement Learning from Human Feedback (RLHF)**

**Reinforcement Learning from AI Feedback (RLAIF)**

*Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna .....*

- Trade-off entre predição e interpretação.
- Em predição estamos interessados em performance preditiva.
- Em inferência o interesse é entender a relação entre variáveis, normalmente como Y muda com uma alterações entre seus determinantes.
- Problema: modelos facilmente interpretáveis (regressões linear e logística, árvores de decisão) normalmente têm pior performance preditiva.
- Pensar bem sobre o objetivo da análise: é inferência ou predição?

## PREDIÇÃO COM MACHINE LEARNING

### Dados

Preferencialmente muitos e com boa qualidade (preenchidos corretamente e preditores fortes). Realizar o pré-processamento das variáveis.

### Algoritmos

Inserir os dados no algoritmo de machine learning para aprender os parâmetros (regressão logística/linear) ou estruturas (árvores) que mapeiam os preditores aos resultados.

### Testar no futuro

Inserir no algoritmo novos dados para testar a qualidade desse algoritmo para prever dados futuros.



# Artigo: How to avoid machine learning pitfalls: a guide for academic researchers

Autor: Michael A. Lones\*

\*School of Mathematical and Computer Sciences, Heriot-Watt University, Edinburgh, Scotland, UK



# Objetivo



- Elencar erros comuns ao aplicar técnicas de machine learning;
- Como evitar esses erros;
- Destina-se como um guia para estudantes;
- Foco em questões de pesquisa acadêmica;

Discussão



1. O que fazer antes de construir um modelo
2. Como construir modelos
3. Como avaliar modelos
4. Como comparar modelos
5. Como relatar resultados

1

# Antes de começar a construir modelos



Entenda os dados



Não olhe para todos os seus dados



Certifique-se de que há dados suficientes



Converse com especialistas no assunto



Faça um levantamento de literatura



Pense em como o modelo será utilizado

1

# Antes de começar a construir modelos



Entenda os  
dados



É importante saber:

- Forma de coleta
- Se há artigos que descreveram o banco de dados
- Se os dados fazem sentido para predição
- Comece sempre por uma análise exploratória

1

# Antes de começar a construir modelos



Entenda os  
dados



Não olhe para  
todos os seus  
dados



Certifique-se de  
que há dados  
suficientes



Converse com  
especialistas no  
assunto



Faça um  
levantamento  
de literatura



Pense em como  
o modelo será  
utilizado



1

## Antes de começar a construir modelos



Não olhe para  
todos os seus  
dados



- Evite analisar os dados de **teste** durante a análise exploratória inicial (suposições consciência ou inconscientes)
- Cuidado com vazamentos (acesso aos dados de teste)

1

# Antes de começar a construir modelos



Entenda os  
dados



Não olhe para  
todos os seus  
dados



Certifique-se de  
que há dados  
suficientes



Converse com  
especialistas no  
assunto



Faça um  
levantamento  
de literatura



Pense em como  
o modelo será  
utilizado

1

# Antes de começar a construir modelos



Certifique-se de  
que há dados  
suficientes



- Sem dados suficientes é impossível treinar um modelo que generalize
  - Descobrir isso pode não ser tão simples (sinal vs ruído)
  - Sinal forte = pode usar menos dados
  - Sinal fraco = precisa de mais dados
- ou usar validação cruzada
- Data Augmentation = aumento no número de observações



Em classificação: importante em dados desbalanceados



Não usar acurácia como  
medida de desempenho

1

# Antes de começar a construir modelos



Entenda os  
dados



Não olhe para  
todos os seus  
dados



Certifique-se de  
que há dados  
suficientes



Converse com  
especialistas no  
assunto



Faça um  
levantamento  
de literatura




Pense em como  
o modelo será  
utilizado

1

# Antes de começar a construir modelos



Converse com  
especialistas no  
assunto



- Ajuda para entender o problema (ex.: variáveis uteis)
- Modelo útil na prática real
- Checar de importância de variáveis fazem sentido e identificar vazamentos

1

# Antes de começar a construir modelos



Entenda os  
dados



Não olhe para  
todos os seus  
dados



Certifique-se de  
que há dados  
suficientes



Converse com  
especialistas no  
assunto



Faça um  
levantamento  
de literatura




Pense em como  
o modelo será  
utilizado

1

# Antes de começar a construir modelos



Faça um  
levantamento  
de literatura



- Entender o que foi feito anteriormente
- Progresso acadêmico = Processo iterativo
- Aproveitar o conhecimento existente



1

## Antes de começar a construir modelos



Entenda os  
dados



Não olhe para  
todos os seus  
dados



Certifique-se de  
que há dados  
suficientes



Converse com  
especialistas no  
assunto



Faça um  
levantamento  
de literatura




Pense em como  
o modelo será  
utilizado

1

# Antes de começar a construir modelos



Pense em como  
o modelo será  
utilizado



- "Por que você quer construir esse modelo?"
- Implementação em ambiente real
- Vinculação do modelo a um Sistema (prontuário eletrônico, aplicativo)

## 2


# Como construir modelos confiáveis



Impeça  
vazamento de  
dados pro teste




Teste vários  
modelos



Não use  
modelos  
inapropriados



Otimize os  
hiperparâmetros



Cuidado com a  
otimização de  
hiperparâmetros e  
seleção de  
variáveis

## 2

# Como construir modelos confiáveis



Impeça  
vazamento de  
dados pro teste




- Separe o conjunto de teste e não mexa nele!
- Vazamento torna modelos inúteis
- Falta de confiabilidade
- Exemplos:
  - Pré-processamento só no treino
  - Seleção de variáveis e otimização de hiperparâmetros só no treino

## 2


# Como construir modelos confiáveis



Impeça vazamento de dados pro teste




Teste vários modelos



Não use modelos inapropriados




Otimize os hiperparâmetros



Cuidado com a otimização de hiperparâmetros e seleção de variáveis

2

## Como construir modelos confiáveis



Teste vários  
modelos



- Não existe um único algoritmo melhor
- Teorema do almoço grátis
- Encontrar algoritmo que gere a melhor predição
- Python: Scikit Learn




## 2


# Como construir modelos confiáveis



Impeça vazamento de dados pro teste




Teste vários modelos



Não use modelos inapropriados




Otimize os hiperparâmetros




Cuidado com a otimização de hiperparâmetros e seleção de variáveis

## 2

# Como construir modelos confiáveis



Não use  
modelos  
inapropriados



- Modelos inadequados aos dados: variáveis categóricas quando o modelo só aceita numéricas
- Modelos desnecessariamente complexos (deep learning para dados estruturados)
- Modelos mais recentes nem sempre são melhores (cuidado com artigos de benchmark em que autores querem que seu algoritmo vença)




## 2


# Como construir modelos confiáveis



Impeça vazamento de dados pro teste




Teste vários modelos



Não use modelos inapropriados



Otimize os hiperparâmetros



Cuidado com a otimização de hiperparâmetros e seleção de variáveis

## 2

# Como construir modelos confiáveis



Otimize os  
hiperparâmetros




- Hiperparâmetros: parâmetros externos ao treinamento que afetam a configuração do modelo
- Hiperparâmetros afetam o desempenho
- Estratégias de otimização (random search, grid search, hyperopt etc)

## 2


# Como construir modelos confiáveis



Impeça vazamento de dados pro teste



Teste vários modelos



Não use modelos inapropriados



Otimize os hiperparâmetros




Cuidado com a otimização de hiperparâmetros e seleção de variáveis

## 2

# Como construir modelos confiáveis



Cuidado com a  
otimização de  
hiperparâmetros e  
seleção de  
variáveis



- Erro comum: seleção de variáveis antes da divisão dos dados
- Seleção estatística de variáveis e otimização de hiperparâmetros devem ser feitas com dados de treino
- Técnica: Validação cruzada aninhada (definição de hiperparâmetros e parâmetros dentro da mesma validação cruzada)

# 3


## Como avaliar modelos




Use um conjunto de teste adequado



Use um conjunto de validação



Avalie o modelo várias vezes



Salve dados para uma avaliação final




Não use a acurácia com dados desbalanceados

# 3

## Como avaliar modelos



Use um conjunto  
de teste  
adequado



- Sempre use um conjunto de teste!
- Dados de teste apropriados (representativo)

# 3


## Como avaliar modelos




Use um conjunto de teste adequado



Use um conjunto de validação



Avalie o modelo várias vezes



Salve dados para uma avaliação final



Não use a acurácia com dados desbalanceados

# 3

## Como avaliar modelos



Use um  
conjunto de  
validação



- Conjunto de validação: conjunto de dados intermediário ao treino e teste, para medir desempenho
- Pode ser usado para orientar o treinamento



# 3


## Como avaliar modelos



Use um conjunto de teste adequado



Use um conjunto de validação



Avalie o modelo várias vezes




Salve dados para uma avaliação final



Não use a acurácia com dados desbalanceados

# 3

## Como avaliar modelos



Avalie o modelo  
várias vezes



- Alguns modelos são instáveis
- Pequenas mudanças no treino podem mudar o desempenho significativamente
- Validação Cruzada (com estratificação em problemas de classificação)

# 3


## Como avaliar modelos



Use um conjunto de teste adequado



Use um conjunto de validação



Avalie o modelo várias vezes




Salve dados para uma avaliação final



Não use a acurácia com dados desbalanceados

# 3

## Como avaliar modelos



Salve dados  
para uma  
avaliação final



- Validação cruzada possui um conjunto de teste pequeno – usar média da performance dos folds
- Usar teste se possível (deixar validação cruzada para seleção de hiperparâmetros)

# 3


## Como avaliar modelos



Use um conjunto de teste adequado



Use um conjunto de validação



Avalie o modelo várias vezes



Salve dados para uma avaliação final



Não use a acurácia com dados desbalanceados

### 3

## Como avaliar modelos

Acurácia




Não use a  
acurácia com  
dados  
desbalanceados



- Cuidado com as métricas de avaliação!
- Acurácia: Em classificação só funciona com amostras balanceadas (mesmo número de observações de ambas classes)
- Os dados de saúde costumam ser desbalanceados

# 4

## Como comparar modelos




Não presuma  
que valores  
maiores  
signifiquem  
modelos  
melhores




Use testes  
estatísticos  
para comparar  
modelos



Faça correções  
para múltiplas  
comparações





Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos



Considere  
combinações de  
modelos

# 4

## Como comparar modelos




Não presuma  
que valores  
maiores  
signifiquem  
modelos  
melhores

- Cuidado ao comparar seus resultados com o de outras pesquisas (diferentes bancos de dados)
- Comparações devem ser justas
- Desempenho depende de como o modelo foi desenvolvido (tipo de dados de treino, formas de avaliação, otimização dos hiperparâmetros, etc)



# 4

## Como comparar modelos




Não presuma  
que números  
maiores  
signifiquem  
modelos  
melhores




Use testes  
estatísticos  
para comparar  
modelos



Faça correções  
para múltiplas  
comparações



Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos



Considere  
combinações de  
modelos

# 4

## Como comparar modelos




Use testes  
estatísticos  
para comparar  
modelos



- Use testes estatísticos para comparações entre algoritmos e com outros trabalhos (debatível)

# 4

## Como comparar modelos




Não presuma  
que valores  
maiores  
signifiquem  
modelos  
melhores




Use testes  
estatísticos  
para comparar  
modelos



Faça correções  
para múltiplas  
comparações



Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos



Considere  
combinações de  
modelos

# 4

## Como comparar modelos




Faça correções  
para múltiplas  
comparações



- Necessidade de testes estatísticos para comparar mais de dois modelos
- Correção para múltiplos testes: Correção de Bonferroni

# 4

## Como comparar modelos



Não presuma  
que valores  
maiores  
signifiquem  
modelos  
melhores




Use testes  
estatísticos  
para comparar  
modelos



Faça correções  
para múltiplas  
comparações



Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos




Considere  
combinações de  
modelos

# 4

## Como comparar modelos




Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos



- Problema da utilização de dados de mesmos bancos
- Desconhecer se não olharam o teste antes
  - Coletivamente o teste está sendo usado muitas vezes (overfitting nesse teste)

# 4

## Como comparar modelos



Não presuma  
que valores  
maiores  
signifiquem  
modelos  
melhores




Use testes  
estatísticos  
para comparar  
modelos



Faça correções  
para múltiplas  
comparações



Nem sempre  
acredite nos  
resultados já  
encontrados em  
outros trabalhos




Considere  
combinações de  
modelos

# 4

## Como comparar modelos



Considere  
combinações de  
modelos




- Compensar pontos fracos com pontos fortes
- Exemplo:
  - Bagging e Boosting
- Como combinar diferentes modelos de base?  
(votação ou usar um algoritmo final para agregação de resultados)



# 5


## Como relatar resultados




Seja  
transparente




Relate o  
desempenho  
de várias  
formas



Não generalize  
para além do seu  
conjunto de  
dados



Cuidado ao  
relatar  
significância  
estatística




Olhe seus  
modelos

# 5

## Como relatar resultados




Seja  
transparente



- Objetivo é contribuir com o conhecimento
- ML possui muitos trade-offs
- Compartilhe o modelo de forma acessível (ex.: github)
- Código limpo e organizado (documente as etapas)
- Facilitar a reprodutibilidade


## 5 Como relatar resultados




Seja  
transparente




Relate o  
desempenho  
de várias  
formas



Não generalize  
para além do seu  
conjunto de  
dados



Cuidado ao  
relatar  
significância  
estatística




Olhe seus  
modelos

## 5 Como relatar resultados




Relate o  
desempenho  
de várias  
formas



- Múltiplos conjuntos de dados para teste
- Relate várias métricas

# 5


## Como relatar resultados




Seja  
transparente




Relate o  
desempenho  
de várias  
formas



Não generalize  
para além do seu  
conjunto de  
dados




Cuidado ao  
relatar  
significância  
estatística



Olhe seus  
modelos

## 5 Como relatar resultados




Não generalize  
para além do seu  
conjunto de  
dados



- Não faça afirmações exageradas
- Esteja ciente das limitações do estudo
- Variações com a qualidade dos dados e diferenças de distribuição

# 5


## Como relatar resultados




Seja  
transparente




Relate o  
desempenho  
de várias  
formas



Não generalize  
para além do seu  
conjunto de  
dados




Cuidado ao  
relatar  
significância  
estatística



Olhe seus  
modelos

## 5 Como relatar resultados




Cuidado ao  
relatar  
significância  
estatística



- Testes estatísticos não são perfeitos!
- Significância estatística: relate o valor  $p$  e deixe que o leitor os interprete




## 5 Como relatar resultados




Seja  
transparente




Relate o  
desempenho  
de várias  
formas



Não generalize  
para além do seu  
conjunto de  
dados




Cuidado ao  
relatar  
significância  
estatística




Olhe seus  
modelos

## 5 Como relatar resultados



Olhe seus  
modelos



- Mostre como o modelo aprendeu e tomou as decisões
- Objetivo: gerar conhecimento
- Forneça visualizações
- Use técnicas de explicabilidade (Shapley)

Em ML assim como em qualquer tipo de pesquisa:

- mantenha a mente aberta
- acompanhe o desenvolvimento da rea
- aceite que você não sabe tudo

## Referência

---

LONES, Michael A. How to avoid machine learning pitfalls: a guide for academic researchers. arXiv preprint arXiv:2108.02497, 2021.



# LABDAPS

LABORATÓRIO DE BIG DATA E  
ANÁLISE PREDITIVA EM SAÚDE

*Obrigado!*

Alexandre Chiavegatto Filho



Alexandre Chiavegatto Filho



@SaudenoBR



@labdaps



alexdiasporto@usp.br

